Описание кода

Этап 1: Загрузка и подготовка данных

Создаётся словарь data с данными о кандидатах — по трём резюме. В нём четыре поля:

- Опыт — стаж работы;
- Навыки — перечень навыков;
- Образование — уровень образования;
- Подходящий — целевая переменная (подходит ли кандидат), закодированная как «Да»/«Нет».

Словарь преобразуется в DataFrame df с помощью pd.DataFrame().

Целевая переменная Подходящий кодируется в бинарный формат: «Да» → 1, «Нет» → 0.

Создаётся новый столбец текст_резюме, объединяющий все текстовые поля в одну строку для дальнейшей обработки.

Этап 2: Преобразование текста в числовой вид

Инициализируется объект CountVectorizer() — инструмент для преобразования текста в числовые векторы на основе частоты слов.

Метод fit_transform() применяется к столбцу текст_резюме:

- строится «словарь» всех уникальных слов из текстов;
- каждый текст преобразуется в вектор, где каждый элемент — количество вхождений соответствующего слова из словаря.

Формируются признаки X (матрица «документ-терм») и целевая переменная y (бинарные метки).

Этап 3: Разделение данных на тренировочную и тестовую выборки

Данные разделяются с помощью train_test_split():

- 80% данных идут в тренировочную выборку (X_train, y_train);
- 20% — в тестовую (X_test, y_test);
- параметр random_state=42 гарантирует воспроизводимость разделения.

Этап 4: Создание и обучение модели

Создаётся экземпляр модели логистической регрессии Logistic Regression().

- Модель обучается на тренировочных данных с помощью метода fit(), настраивая веса для каждого признака (слова) для предсказания целевой переменной.

Этап 5: Прогнозирование и оценка модели

Обученная модель делает предсказания для тестовой выборки с помощью predict().

Рассчитываются метрики качества:

- Accuracy (accuracy_score) — доля правильных предсказаний от общего числа;
- Precision (precision_score) — доля истинно положительных среди всех положительных предсказаний;
- Recall (recall_score) — доля истинно положительных, найденных моделью, от всех реальных положительных;
- F1 Score (f1_score) — гармоническое среднее между Precision и Recall.

Результаты выводятся на экран с округлением до двух знаков после запятой.

Вывод

Код реализует конвейер машинного обучения для классификации резюме на «подходящий»/«неподходящий» кандидат. Основные особенности:

- Тип задачи: бинарная классификация.
- Метод векторизации: Bag-of-Words (CountVectorizer).
- Модель: логистическая регрессия.
- Оценка: четыре ключевые метрики (Accuracy, Precision, Recall, F1).